

DATA SCIENCE · STATISTICS PRACTICE

건물 특성과 에너지 효율성의 관계 분석

기초통계량과 변수 관계를 학습하고 Y1·Y2 독립 선형회귀 모델로 연결한 과정

SUMMARY

핵심 요약 UCI Energy Efficiency 768개 설계 데이터를 평균·중앙값·표준편차·왜도·초과첨도와 변수 관계로 해석하였다. 설명변수의 중복과 건물 특성의 의미를 함께 고려해 X2·X3·X5·X7을 선택하고, Y1과 Y2를 각각 독립적인 LinearRegression 모델로 학습하였다.

Y1 Test R^2 는 0.9059, Y2 Test R^2 는 0.8869로 테스트 표본에서 각 목표변수 변동의 약 90.6%, 88.7%를 설명하였다. 다만 잔차에는 구간별 층과 분산 차이, 꼬리 이탈이 남아 있어 선형성·정규성·등분산성이 완전히 충족된다고 단정하지 않았다. 본 분석의 핵심 학습은 상관계수의 크기만으로 변수를 고르지 않고, 분포·중복·범주 코드의 의미·도메인 해석을 함께 연결한 것이다.

공개 전 직접 수정

아래 노란색 '나의 학습 메모'에 본인이 실제로 느낀 점을 1~2문장으로 바꿔 쓰세요. 공개가 필요하지 않은 개인 정보가 포함되지 않았는지도 확인하고, 수정이 끝나면 이 메모 상자를 삭제해도 됩니다.

목차

1. 분석 목적과 학습 질문
2. 데이터와 분석 범위
3. 기술통계량: 중심·퍼짐·분포
4. 변수 간 관계와 범주형 코드 해석
5. EDA 기반 변수 선정
6. Y1·Y2 독립 선형회귀 모델
7. 잔차와 선형회귀 가정 점검
8. 결론과 학습 회고

EDA에서 모델 개발까지의 학습 흐름



그림 1. 통계량 확인에서 모델 해석으로 이어지는 학습 흐름

나의 학습 메모

[예시] 처음에는 상관계수가 큰 변수를 모두 사용하면 된다고 생각했다. 분석을 진행하면서 설명변수끼리 같은 정보를 반복하는지와 숫자가 실제 물리량인지도 확인해야 한다는 점을 배웠다.

1. 분석 목적과 학습 질문

이번 분석의 목적은 가장 높은 예측 성능을 만드는 것이 아니라, 수업에서 배운 기초통계량과 상관관계를 이용해 건물 특성과 에너지 부하 사이의 관계를 해석하고 그 판단을 선형회귀 모델로 연결하는 것이다.

1.1 분석 전 질문

- Y1과 Y2의 중심과 퍼짐은 어느 정도이며 분포는 대칭적인가?
- 어떤 건물 특성이 Y1과 Y2에 비교적 강한 선형관계를 보이는가?
- 상관이 큰 변수를 모두 넣어도 되는가, 아니면 같은 정보를 반복하는 변수가 있는가?
- X6·X8처럼 숫자로 기록된 범주 코드는 어떻게 해석해야 하는가?
- 최종 선형모델은 목표변수 변동을 어느 정도 설명하며 잔차에는 어떤 한계가 남는가?

1.2 선택한 모델링 방식

Separate Models를 선택하였다. Y1과 Y2는 서로 다른 목표변수이므로 별도의 LinearRegression 객체로 학습하였다. 두 목표가 동일한 설계 조건에서 측정되었기 때문에 결과를 같은 기준으로 비교하려고 공통 설명변수를 사용했으며, 한 목표변수를 다른 모델의 입력으로 넣지 않았다.

나의 학습 메모

[직접 작성] Separate Models를 선택한 이유와 Chained Predictions를 사용하지 않은 이유를 본인의 말로 1~2문장 작성하세요.

2. 데이터와 분석 범위

구분	변수	의미
형상	X1~X5	상대적 집약도, 표면적, 벽 면적, 지붕 면적, 전체 높이
범주·창호	X6~X8	방향 코드, 유리창 면적, 유리창 분포 유형 코드
목표	Y1, Y2	난방 부하, 냉방 부하(출처에 물리 단위 미기재)

데이터는 UCI Machine Learning Repository의 Energy Efficiency 원본이며 768행, 8개 설명변수, 2개 목표 변수로 구성된다. 결측치는 없었다. X6과 X8은 숫자로 저장되어 있지만 연속적인 물리량이 아니라 범주형 코드이므로 Pearson 상관계수만으로 중요도를 판단하지 않았다.

3. 기술통계량: 중심·퍼짐·분포

목표	평균	중앙값	표준편차	왜도	초과첨도	최소	최대
Y1	22.307	18.950	10.090	0.360	-1.246	6.010	43.100
Y2	24.588	22.080	9.513	0.396	-1.147	10.900	48.030




그림 2. Y1·Y2 히스토그램과 상자그림

3.1 숫자를 읽으며 수정한 생각

처음에는 평균과 표준편차만으로 목표변수의 일반적인 크기를 충분히 설명할 수 있다고 생각했다. 그러나 Y1·Y2 모두 평균이 중앙값보다 높고 왜도가 양수였으며, 히스토그램에는 하나의 매끄러운 정규분포라기보다 여러 설계 군이 섞인 형태가 보였다. 따라서 평균 하나로 요약하기보다 형상·창호 조건에 따른 관계를 함께 확인해야 한다고 판단했다.

통계 용어 pandas의 kurt()는 정규분포를 0으로 두는 초과첨도이다. 음의 초과첨도만으로 봉우리 모양을 단정하지 않고 히스토그램과 함께 해석하였다. 또한 데이터 출처에 물리 단위가 명시되지 않아 kWh를 임의로 붙이지 않았다.

4. 변수 간 관계와 범주형 코드 해석




그림 3. 전체 수치 변수의 Pearson 상관행렬

변수	Y1 상관	Y2 상관	해석 초점
X2 표면적	-0.658	-0.673	외피 규모를 나타내는 대표 후보
X3 벽 면적	0.456	0.427	벽 면적이라는 별도의 구조 정보
X5 전체 높이	0.889	0.896	두 목표와 비교적 강한 양의

변수	Y1 상관	Y2 상관	해석 초점
			선형관계
X7 유리창 면적	0.270	0.208	약하지만 별도의 창호 면적 특성
Y1·Y2	0.975862	0.975862	같은 설계에서 두 부하가 강하게 함께 변화

이 데이터에서는 X5가 큰 설계군에서 Y1과 Y2가 상대적으로 높은 경향이 관찰되었다. 그러나 상관관계와 회귀계수만으로 X5가 부하 증가의 직접적인 원인이라고 단정할 수 없다. X7도 창호 면적과 부하가 함께 변하는 경향을 보여주지만 열손실이나 일사 유입이라는 원인을 현재 분석만으로 확정할 수는 없다.




그림 4. X5·X7과 Y1·Y2의 관계 비교

4.1 X6 방향 코드는 그룹으로 비교

X6	Y1 평균	Y1 중앙값	Y1 표준편차	Y2 평균	Y2 중앙값	Y2 표준편차	표본
2	22.313	19.130	10.109	24.605	22.220	9.609	192
3	22.381	19.005	10.140	24.313	21.755	9.310	192

X6	Y1 평균	Y1 중앙값	Y1 표준편차	Y2 평균	Y2 중앙값	Y2 표준편차	표본
4	22.260	18.950	10.119	24.480	22.170	9.375	192
5	22.275	18.650	10.071	24.954	22.510	9.813	192




그림 5. X6 방향 그룹별 Y1·Y2 분포

X6은 방향 코드이므로 코드 간 차이에 연속적인 선형 의미를 부여하지 않았다. Y1 그룹 평균은 22.260~22.381, Y2 그룹 평균은 24.313~24.954였고 상자그림도 크게 겹쳤다. 그룹 중심 차이는 각 그룹 내부 표준편차보다 작게 관찰되었다. 이는 이 데이터의 기술적 비교이며 방향의 일반적인 효과가 없다는 결론은 아니다.

5. EDA 기반 변수 선정

5.1 중복 관계 확인

X1-X2 상관은 -0.992, X4-X5 상관은 -0.973이었다. 따라서 목표변수와의 상관이 크다는 이유만으로 X1·X2·X4·X5를 모두 사용하면 같은 형상 정보를 반복해서 반영할 수 있다. 규모를 대표하는 X2와 높이 특성을 나타내는 X5를 남기고 X1·X4는 제외하였다.

5.2 최종 변수 판단

변수	통계적 근거	건물 특성 의미	결정
X2	Y1 -0.658, Y2 -0.673; X1과 강한 중복	외피 규모 대표	선택
X3	Y1 0.456, Y2 0.427	벽 면적 특성	선택
X5	Y1 0.889, Y2 0.896; X4와 강한 중복	높이 특성 대표	선택
X7	Y1 0.270, Y2 0.208	별도의 창호 면적 특성	선택
X1·X4	대표 변수와 정보 중복	형상 정보 반복	제외
X6	그룹별 중심·분포로 비교	방향 범주 코드	제외
X8	숫자 간 물리적 간격 없음	유리창 분포 유형 코드	제외

최종 공통 설명변수 X2, X3, X5, X7. 상관계수가 높은 순서만으로 선택하지 않고 Y1·Y2 관계, 설명변수 중복, 건물 특성의 의미, 범주형 코드의 해석 한계를 함께 고려하였다.

나의 학습 메모

[직접 작성] X7처럼 상관이 상대적으로 약한 변수를 남긴 이유를 본인의 말로 다시 설명해보세요.

6. Y1·Y2 독립 선형회귀 모델

동일한 X_train·X_test 행을 사용하되 model_y1과 model_y2를 별도 객체로 생성하였다. Y1을 Y2 모델의 입력으로 사용하지 않았고 Y2도 Y1 모델의 입력으로 사용하지 않았다. test_size=0.2, random_state=42를 사용했으며 별도의 최적화는 수행하지 않았다.

모델	Train R ²	Test R ²	R ² 차이	Test MAE	Test RMSE
Y1	0.911977	0.905891	0.006086	2.325039	3.131971
Y2	0.879865	0.886931	-0.007066	2.290870	3.236767

모델	절편	X2	X3	X5	X7
Y1	-32.325308	0.013107	0.039261	5.407255	20.801520
Y2	-28.342300	0.019318	0.023052	5.523195	15.067152




그림 6. 테스트 데이터의 실제값과 예측값 비교

6.1 성능을 공부하는 관점에서 해석

Y1 Test R² 0.9059는 테스트 Y1 변동의 약 90.6%를 모델이 설명했다는 뜻이며 예측 정확도와 같은 표현은 아니다. Y2 Test R² 0.8869도 같은 방식으로 약 88.7%의 변동을 설명한다. MAE는 실제값과 예측값 사이의 평균 절대 오차다. 두 모델 모두 RMSE가 MAE보다 커 일부 상대적으로 큰 오차의 영향을 받았을 가능성이 있다.

7. 잔차와 선형회귀 가정 점검




그림 7. Y1·Y2 잔차 산점도, 히스토그램, Q-Q plot

항목	Y1	Y2
잔차 평균	0.300197	0.417481
잔차 왜도	0.082857	0.883403
최대 절대잔차	8.261903	11.670663

- 실제값-예측값: 두 산점도는 대체로 기준선 주변이지만 높은 부하 구간에서 비교적 큰 오차가 관찰되었다.
- 선형성: 잔차에 층과 굴곡이 남아 완전한 선형관계가 충족된다고 단정하기 어렵다.
- 등분산성: 예측값 약 25 이상 구간에서 잔차 폭이 더 넓어지는 모습이 있다.
- 정규성: Y1 잔차는 비교적 대칭적이지만 Q-Q 꼬리가 벗어난다. Y2는 오른쪽 치우침이 더 크다.
- 큰 오차: Y2 최대 절대잔차가 약 11.67로 Y1보다 크게 관찰되었다.

판단 두 모델은 수업 범위 안의 기초 선형 기준모델로 의미가 있지만, 잔차의 층 구조·구간별 분산 차이·꼬리 이탈 때문에 선형성·정규성·등분산성이 완전히 충족된다고 말할 수 없다.

8. 결론과 학습 회고

1. 이 데이터에서는 전체 높이와 표면적 등 건물 형상 변수가 $Y1 \cdot Y2$ 에 비교적 강한 선형관계를 보였다. 그러나 이를 직접적인 인과관계로 해석하지 않았다.
2. $X7$ 은 상관이 상대적으로 약해도 별도의 상호 면적 특성을 나타내므로 유지했다. 상관계수 순위와 도메인 의미가 항상 같은 것은 아니라는 점을 배웠다.
3. $X6 \cdot X8$ 은 숫자로 저장된 범주 코드다. 숫자형 자료라고 해서 항상 연속형 변수처럼 다룰 수 있는 것은 아니다.
4. $Y1 \cdot Y2$ 모델은 높은 설명력을 보였지만 잔차 진단을 통해 선형모델의 한계도 함께 확인했다.
5. 시뮬레이션 데이터이며 기후·재료·운영시간 변수가 없으므로 실제 건물 전체로 일반화할 수 없다.

최종 학습 회고 — 직접 수정

[직접 작성] 이번 과제를 통해 가장 크게 바뀐 생각, 어려웠던 부분, 다음에 더 분석하고 싶은 질문을 3~5문장으로 작성하세요. 예: ‘처음에는 상관계수가 변수 중요도라고 생각했지만...’

참고자료

Tsanas, A. & Xifara, A. (2012). Energy Efficiency [Dataset]. UCI Machine Learning Repository.
<https://doi.org/10.24432/C51307>

수업 노트: descriptive statistics, correlation, linear regression.